MACHINE LEARNING ALGORITHMS DESIGN

- DEBUGGING LEARNING ALGORITHM
  - SUPPONIAMO DI AVER IMPLEMENTATO LINEAR REGRESSION CON REGOLARIZZAZIONE, MA GLI ERRORI SU NUOVI CAMPIONI SONO COMUNQUE "GRANDI".
    QUALE STRATEGIA POSSIAMO APPLICARE PER CERCARE DI MIGLIORARE?

DIFFERENZA TRA (A) PRATICONE ED (B) ESPERTO

(A) VA A CASACCIO PER CERCARE DI MIGLIORARE I RISULTATI (SPESSO LA SOLUZIONE CHE PROPONE E' QUELLA DI AUMENTARE IL NUMERO DI CAMPIONI DELLA BANCA DATI DI TRAINING. QUESTO NON E' SEMPRE UNA BUONA SOLUZIONE... ANZI!)

(B) CONOSCE LA FORMULAZIONE TEORICA DEGLI ALGORITMI (CHE INCLUDE ANCHE PARAMETRI E HYPER PARAMETRI DA TUNARE). SI ADOPERA PER METTERE IN PIEDI PROCESSI DI DEBUG CHE PERMETTE DI COMPRENDERE COME PROCEDERE

1) AUMENTARE I CAMPIONI DI TRAINING
2) PROVA A RIDURRE IL SET DI FEATURES (ELIMINA RIDONDANZE)
3) PROVA A CERCARE NUOVE FEATURES UTILI A RISOLVERE IL PROBLEMA
4) PROVA AD UTILIZZARE FEATURE POLINOMIALI $(x_1^2, x_2^2, x_1x_2, \dots)$
5) PROVA AD INCREMENTARE/DECREMENTARE λ
   ↳ REGULARIZATION PARAMETER

SOLITAMENTE SI CERCA DI EFFETTUARE TEST DIAGNOSTICI CHE PERMETTONO DI OTTENERE INFORMAZIONI DETTAGLIATE SU COSA FUNZIONA/NON FUNZIONA COSI' DA OTTENERE INDICAZIONI PER MIGLIORARE LE PRESTAZIONI

⇒ NECESSITA TEMPO DI IMPLEMENTAZIONE MA E' TEMPO SPESO BENE! NON ANDARE HAI A CASACCIO!!

VALUTAZIONE DEI MODELLI

- NECESSARIO SPLITTARE TRAINING IN TRAINING/VAL/TEST

80% TRAINING, 20% TEST, 20% VAL

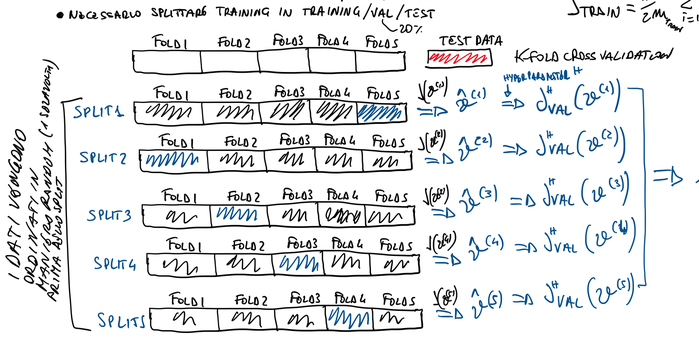

$$J(\theta) = \frac{1}{2m_{train}} \sum_{i=1}^{m_{train}} \left(h_\theta(x_{train}^{(i)}) - y_{train}^{(i)} \right)^2 + \frac{\lambda}{2m_{train}} \sum_{j=1}^{d} \theta_j^2 \quad \text{(} \times \text{REGRESSIONE)}$$

$$J_{TRAIN} = \frac{1}{2m_{train}} \sum_{i=1}^{m_{train}} \left(h_\theta(x_{train}^{(i)}) - y_{train}^{(i)} \right)^2 \qquad J_{VAL}(\theta) = \frac{1}{2m_{val}} \sum_{i=1}^{m_{val}} \left(h_\theta(x_{val}^{(i)}) - y_{val}^{(i)} \right)^2$$

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} \left(h_\theta(x_{test}^{(i)}) - y_{test}^{(i)} \right)^2$$

SPLIT1: $J(\theta^{(1)}) \Rightarrow \theta^{(1)} \Rightarrow J_{VAL}^{H}(\theta^{(1)})$
SPLIT2: $J(\theta^{(2)}) \Rightarrow \theta^{(2)} \Rightarrow J_{VAL}^{H}(\theta^{(2)})$
SPLIT3: $J(\theta^{(3)}) \Rightarrow \theta^{(3)} \Rightarrow J_{VAL}^{H}(\theta^{(3)})$
SPLIT4: $J(\theta^{(4)}) \Rightarrow \theta^{(4)} \Rightarrow J_{VAL}^{H}(\theta^{(4)})$
SPLIT5: $J(\theta^{(5)}) \Rightarrow \theta^{(5)} \Rightarrow J_{VAL}^{H}(\theta^{(5)})$

(HYPERPARAMETRI H)

$$\Rightarrow \frac{1}{5} \sum_{K=1}^{5} J_{VAL}^{H}(\theta^{(K)})$$

(K FOLD QUI K=5)

QUANDO AL VARIARE DI H SI OTTENGONO DIVERSI VALORI MEDI

⇒ SCEGLI HYPERPARAMETRI H CHE HA DANNO MODELLO MINIMO SU J_{VAL}

⇒ FISSATO IL MIGLIOR HYPERPARAMETRO H POSSIAMO EFFETTUARE TRAINING SULLE 5 FOLD E POI TESTARE SUI DATI DI TEST

CAPITA SPESSO DI SUDDIVIDERE DATI SOLO CON 1 FOLD
↳ DATASET ENORMI

IN QUESTO MODO, NESSUNO DEI PARAMETRI O IPERPARAMETRI DELL'ALGORITMO HA USATO DATI DI TEST!

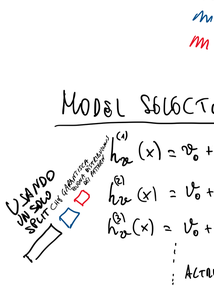

$h_\theta^{(1)}(x) = \theta_0 + \theta_1 x_1$
$h_\theta^{(2)}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2$
$h_\theta^{(3)}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + x_1^3$
⋮
ALTRI MODELLI SCELTI

$\min_\theta J(\theta)$	$J_{VAL}(\theta)$
$\theta^{(1)}$	$J_{VAL}(\theta^{(1)})$
$\theta^{(2)}$	$J_{VAL}(\theta^{(2)})$
$\theta^{(3)}$	$J_{VAL}(\theta^{(3)})$
⋮	⋮

⇒ PRENDI I PARAMETRI CHE CORRISPONDONO AL MIGLIOR MODELLO TESTATO SUL VAL
⇓
TESTA SUL TEST SET
$J_{TEST}(\theta^{(best)})$ ERRORE DI GENERALIZZAZIONE

MODEL SELECTION

BIAS VS VARIANCE

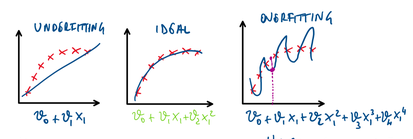

HIGH BIAS (POOR ASSUMPTION IN THE MODEL) OR HIGH VARIANCE

SUPPONIAMO CHE IL NOSTRO ALGORITMO NON OTTENGA RISULTATI SPERATI (OVVERO $J_{VAL}(\theta)$ OPPURE $J_{TEST}(\theta)$ SONO "GRANDI"). E' UN PROBLEMA DI HIGH BIAS OPPURE DI HIGH VARIANCE?
⇒ STUDIA LE CURVE!

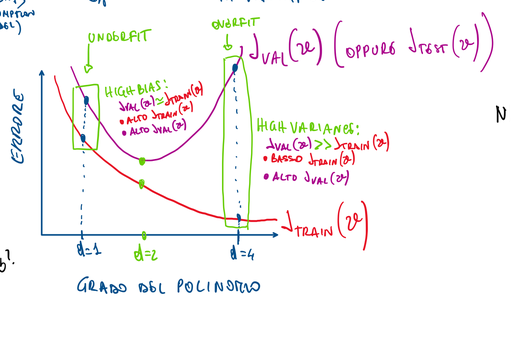

NB: STIAMO CONSIDERANDO J_{TRAIN}, J_{VAL}, J_{TEST} CHE NON INCLUDONO TERMINE DI REGOLARIZZAZIONE (VIA IN FASE DI LEARNING DEI PARAMETRI USANDO $J(\theta)$ IN CUI E' PRESENTE TERMINE DI REGOLARIZZAZIONE)

SCELTA DEL PARAMETRO DI REGOLARIZZAZIONE λ

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 + \frac{\lambda}{2m} \sum_{j=1}^{n} \theta_j^2$$

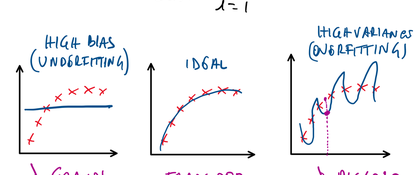

λ PICCOLO → SI VA VERSO IL MODELLO SENZA REGOLARIZZAZIONE AL DECRESCERE DI λ

↳ IN $J(\theta)$ LA $\sum_{j=1}^{n} \theta_j^2$ POSSIBILE' MOLTO GRANDE QUINDI θ_j TENDERANNO AD ESSERE PICCOLI ⇒ $h_\theta(x) \simeq \theta_0$

ANCHE IN QUESTO CASO COME PER LA SELEZIONE DEL MODELLO SI PROCEDE SPERIMENTALMENTE

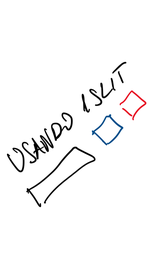

$\lambda^{(1)} = 0$
$\lambda^{(2)} = 0.01$
$\lambda^{(3)} = 0.02$
$\lambda^{(4)} = 0.04$
$\lambda^{(5)} = 0.08$
⋮
$\lambda^{(K)} = 100$

$\Rightarrow \min_\theta J(\theta) \Rightarrow \theta^{(1)}, \theta^{(2)}, \theta^{(3)}, \dots, \theta^{(K)} \Rightarrow J_{VAL}(\theta^{(1)}), J_{VAL}(\theta^{(2)}), \dots, J_{VAL}(\theta^{(K)}) \Rightarrow$ BEST J_{VAL} $J_{VAL}(\theta^{(best)}) \Rightarrow J_{TEST}(\theta^{(best)})$

COMPRENSIONE DELLE CURVE RISPETTO A λ

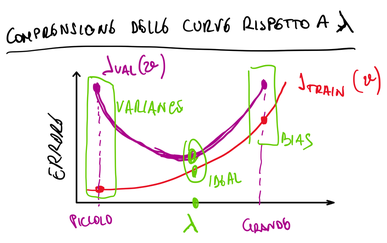

VARIANCE: $J_{VAL} >> J_{TRAIN}$
J_{VAL} GRANDE
J_{TRAIN} PICCOLO

BIAS: $J_{VAL} \simeq J_{TRAIN}$
J_{VAL} GRANDE
J_{TRAIN} GRANDE

ALTRE CURVE

ERRORE VS DIMENSIONE DATASET TRAINING

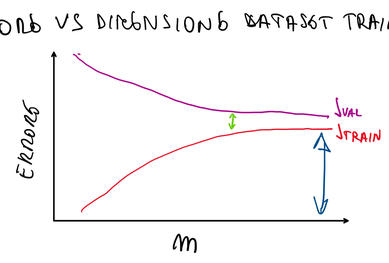

$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x^2$

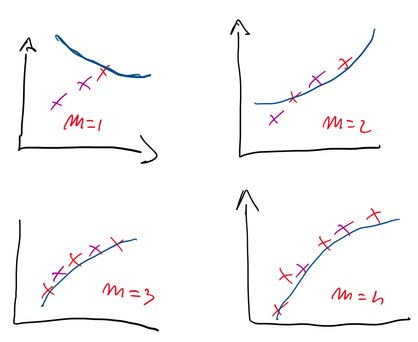

NB: SE SIAMO IN PRESENZA DI HIGH BIAS (OVVERO ↕ GRANDE ↕ PICCOLO) AUMENTARE IL NUMERO DEI DATI DI TRAINING NON AIUTA MOLTO!

AL CRESCERE DI m CRESCE ERRORE TRAINING MA ALLO STESSO TEMPO DECRESCE QUELLO DEL VALIDATION

NB: SE SIAMO IN PRESENZA DI HIGH VARIANCE (OVVERO ↕ GRANDE ↕ PICCOLO) AUMENTARE IL NUMERO DI DATI DI TRAINING POTREBBE AIUTARE A MIGLIORARE I RISULTATI (MA NON E' DETTO CHE AIUTI SEMPRE)

TIPS & TRICKS

- AUMENTARE IL NUMERO DI DATI DI TRAINING → UTILE A RISOLVERE PROBLEMI DI HIGH VARIANCE (OVERFITTING) (HA UN COSTO ALTO. I MODERN DIAGNOSTICI PERMETTONO DI CAPIRE SE NE VALE LA PENA)
- DIMINUIRE SET FEATURE → UTILE IN CASO DI HIGH VARIANCE
- AUMENTARE SET FEATURE → UTILE IN CASO DI HIGH BIAS
- USARE POLINOMIAL KERNEL → UTILE IN CASO DI HIGH BIAS
- DECREMENTARE λ ⇒ UTILE IN CASO DI HIGH BIAS
- INCREMENTARE λ ⇒ UTILE IN CASO DI HIGH VARIANCE