MULTI-CLASS CLASSIFICATION

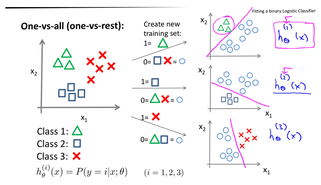

ONE VS ALL: FAI IL TRAINING DEL CLASSIFICATORE BINARIO $h_\theta^{(K)}(x)$ PER OGNI CLASSE K

AL FINE DI PREDIRE LA PROBABILITA' $P(y=K|x;\theta)$

QUANDO SI DEVE CLASSIFICARE UN NUOVO ESEMPIO x^{NEW} BISOGNERA' PRENDERE LA CLASSE CORRISPONDENTE AL CLASSIFICATORE $h_\theta^{(K)}$ CHE HA PROBABILITA' MAGGIORE

$$\hat{K} = \max_K h_\theta^{(K)}(x^{NEW})$$

ESEMPIO

$h_\theta^{(1)}(x^{NEW}) = 0.3$

$h_\theta^{(2)}(x^{NEW}) = 0.8 \Rightarrow$ CLASSE 2

$h_\theta^{(3)}(x^{NEW}) = 0.1$

NB: $\sum_c h_\theta^{(c)}(x^{NEW})$ PUO' ASSUMERE VALORI MAGGIORI DI 1 (I 3 OUTPUT NON FORMANO UNA DISTRIBUZIONE DI PROBABILITA')

E se tutti e tre i classificatori avessero un valore di output minore di 0,5?

E' corretto classificare prendendo in considerazione il classificatore che ha il valore massimo sebbene minore di 0,5? (es. se il classificatore 1 ha il valore massimo tra i tre classificatori e il suo valore è pari a 0.4, valore che per quanto detto indica che è più probabile che il pattern non sia di classe 1 ma di una delle altre due classi, è corretto classificarlo come di classe 1?)

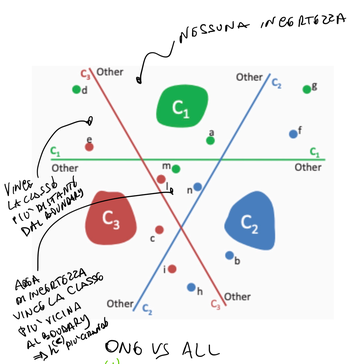

ONE VS ALL

"DISTANZA DAL BOUNDARY"

$h_{\theta_1}^{(1)}(m) < 0.5$

$h_{\theta_2}^{(2)}(m) < 0.5$

$h_{\theta_3}^{(3)}(m) < 0.5$

$h_{\theta_2}^{(2)}(m) < h_{\theta_1}^{(1)}(m)$

$\Rightarrow$ CLASSE C_2

ESEMPIO

m

l

n

OVERFITTING E REGOLARIZZAZIONE

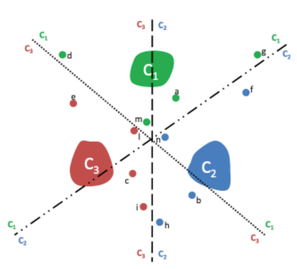

ONE VS ONE

C_1 VS C_2 VOTA PER C_1

C_3 V C_2 VOTA PER C_3

C_1 V C_3 VOTA PER C_3

C_1	C_2	C_3
2	0	1

2 VOTI PER $C_3 \Rightarrow$ CLASSE C_3

ANCHE IN QUESTO CASO SI PUO' RAGIONARE IN TERMINI DI DISTANZA DAL BOUNDARY PERO' TORNANO IN CONSIDERAZIONE LE CLASSI C_1 & C_3

CON K CLASSI $\frac{K(K-1)}{2}$ CLASSIFICATORI

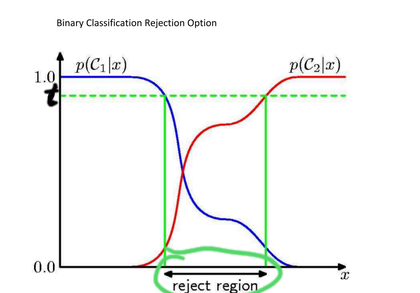

VALORI DI INPUT PER CUI NON DECIDIAMO

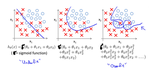

$$J(\theta) = -\frac{1}{m}\left[\sum_{i=1}^{m} y^{(i)} \log(h_\theta(x^{(i)})) + (1-y^{(i)}) \log(1-h_\theta(x^{(i)}))\right] + \frac{\lambda}{2m}\sum_{j=1}^{n} \theta_j^2$$

NELL'ALGORITMO DI DISCESA DEL GRADIENTE SI AGGIUNGE LA DERIVATA DEL TERMINE DI REGOLARIZZAZIONE PER TUTTI I θ_j $\forall j = 1,\dots,n$

RIPETI {

$$\theta_0^{new} \leftarrow \theta_0^{old} - \alpha \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_0$$

$$\theta_j^{new} \leftarrow \theta_j^{old} - \alpha\left[\frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j + \frac{\lambda}{m}\theta_j\right] \quad \forall j = 1,\dots,n$$

$\}$

$\theta_j(\theta^T x^{(i)})$

FORMA USATA X LA CLASSIFICAZIONE

$J(\theta) \leftarrow$ FUNZIONE OTTIMIZZAZIONE PARAMETRI DI REGOLARIZZATA (CALCOLATA SUL TRAINING)

$J_{TRAIN} \Rightarrow$ UGUALE A $J(\theta)$ MA NON INCLUDE TERMINE DI REGOLARIZZAZIONE (CALCOLATA SUL TRAINING SET)

$J_{VAL} \Rightarrow$ UGUALE A $J(\theta)$ MA NON INCLUDE TERMINE DI REGOLARIZZAZIONE (CALCOLATA SUL VALIDATION SET)

$J_{TEST} \Rightarrow$ CALCOLATA SUL TEST SET. UGUALE A $J(\theta)$ MA NON CONSIDERA TERMINE DI REGOLARIZZAZIONE

$$\text{ERROR} = \frac{1}{m}\sum_{i=1}^{m} \text{ERROR}\left(h_\theta(x^{(i)}), y^{(i)}\right) \qquad \text{ERROR}\left(h_\theta(x^{(i)}), y^{(i)}\right) = \begin{cases} 1 & \text{IF } \left(\left(h_\theta(x^{(i)}) \geq 0.5\right) \text{AND} \left(y^{(i)} = 0\right)\right) \text{OR} \left(\left(h_\theta(x^{(i)}) < 0.5\right) \text{AND} \left(y^{(i)} \geq 1\right)\right) \\ 0 & \text{IF } \left(\left(h_\theta(x^{(i)}) \geq 0.5\right) \text{AND} \left(y^{(i)} = 1\right)\right) \text{OR} \left(\left(h_\theta(x^{(i)}) < 0.5\right) \text{AND} \left(y^{(i)} \geq 0\right)\right) \end{cases}$$

MISCLASSIFICATION ERROR = FRAZIONE DI PATTERN ERRONEAMENTE CLASSIFICATI

STOCHASTIC GRADIENT DESCENT (SGD)

OSSERVAZIONI: LA DISCESA DEL GRADIENTE COMPUTA $J(\theta)$ SU TUTTI I CAMPIONI DEL TRAINING SET.

LA SOMMA DEI RESIDUI CALCOLATA SU m TERMINI AD OGNI ITERAZIONE DELLA DISCESA DEL GRADIENTE CHE VIENE MOLTIPLICATA α VOLTE PER I VALORI DELLE COMPONENTI AL CRESCERE DI $m \in$ DI α IL PROBLEMA ESEGUE CONFRONTABILMENTE LENTO

1000 CAMPIONI = m

100 FEATURE = α $\Rightarrow$ $m \times \alpha$ OPERAZIONI AD OGNI ITERAZIONE

M ITERAZIONI GRADIENT DESCENT $\Downarrow$ 1000 000 PER OGNI ITERAZIONE

$m \times 1000\,000$

SE M VALE ANCHE SOLO 1000

$\Downarrow$

1 000 000 000 OPERAZIONI

$\Rightarrow$ STOCASTIC IS SUPER HERO!

STOCASTIC = RANDOM

1) CAMPIONA RANDOM UN SET DI PICCOLI PUNTI DAL TRAINING (UN MINI BATCH)
2) ESEGUI L'ITERAZIONE DEL GRADIENT DESCENT DI DISCESA DEL GRADIENTE SUI PUNTI CAMPIONATI
3) TORNA AL PUNTO 1 SE NON SEI ARRIVATO A CONVERGENZA

VALUTAZIONE CLASSIFICAZIONE BINARIA

MATRICE DI CONFUSIONE

		ETICHETTE PREDETTE: POSITIVO	ETICHETTE PREDETTE: NEGATIVO
ETICHETTE VERE	POSITIVO	a	c
ETICHETTE VERE	NEGATIVO	d	b

GOAL

a $\in$ b GRANDI

c $\in$ d PICCOLI

IN PERCENTUALE

a = NUMERO DEI CAMPIONI DI CLASSE POSITIVA CLASSIFICATI COME POSITIVI DAL NOSTRO ALGORITMO $\Rightarrow$ VERI POSITIVI $\Rightarrow$ TP = $\frac{a}{a+c}$

b = NUMERO DI CAMPIONI DI CLASSE NEGATIVA CLASSIFICATI CORRETTAMENTE COME NEGATIVI DALL'ALGORITMO $\Rightarrow$ VERI NEGATIVI $\Rightarrow$ TN = $\frac{b}{b+d}$

c = NUMERO DI CAMPIONI POSITIVI CLASSIFICATI ERRONEAMENTE COME NEGATIVI DAL MODELLO $\Rightarrow$ FALSI NEGATIVI $\Rightarrow$ FN = $\frac{c}{c+a}$

d = NUMERO DI CAMPIONI NEGATIVI CLASSIFICATI ERRONEAMENTE COME POSITIVI DAL MODELLO $\Rightarrow$ FALSI POSITIVI $\Rightarrow$ FP = $\frac{d}{d+b}$

a+c = TOTALE DEI CAMPIONI POSITIVI NELLA BANCA DATI DI TEST

d+b = TOTALE DEI CAMPIONI NEGATIVI NELLA BANCA DATI DI TEST

TP + FN = 1

TN + FP = 1

ACCURACY $\frac{a+b}{a+b+c+d}$ PERCENTUALE DEI CAMPIONI CORRETTAMENTE CLASSIFICATI

ATTENZIONE AD AVERE SET DI TEST BILANCIATI NEL NUMERO DI CAMPIONI DELLE DIVERSE CLASSI (NON E' SEMPRE POSSIBILE, MA BISOGNA TENERNE CONTO IN FASE DI VALUTAZIONE) $\Rightarrow$ MA PERCHE'?

PRECISION

$$\frac{\text{TRUE POSITIVE } a}{\text{TRUE POSITIVE } a + \text{FALSE POSITIVE } d}$$

DI TUTTI I CASI CHE SONO STATI PREDETTI COME POSITIVI, QUALE FRAZIONE SONO EFFETTIVAMENTE POSITIVI? WE WANT LOW FALSE POSITIVE

RECALL

$$\frac{\text{TRUE POSITIVE } a}{\text{TRUE POSITIVE } a + \text{FALSE NEGATIVE } c}$$

DI TUTTI I CASI POSITIVI, QUALE FRAZIONE ABBIAMO CORRETTAMENTE ETICHETTATO COME POSITIVI? WE WANT LOW FALSE NEGATIVE

MOMENTUM

ALCUNE FUNZIONI POSSONO ESSERE DIFFICILI DA OTTIMIZZARE PER CUI SGD HA DIFFICOLTA' A TROVARE IL MINIMO LINK https://distill.pub/2017/momentum/

AGGIORNAMENTO CON MOMENTUM

$$v^{new} \leftarrow v^{old} - \alpha \nabla J(\theta^{old})$$

$$\theta^{new} \leftarrow \theta^{old} + v^{new}$$

MOMENTUM PARAMETER

$\beta = 0 \Rightarrow$ CLASSIC GRADIENT DESCENT

$\Rightarrow$ ONE MORE PARAMETER TO SET!

LEARNING RATE DECAY

- DURANTE LA FASE DI TRAINING E' SPESSO UTILE RIDURRE IL LEARNING RATE (LO SCOPO E' EVITARE OSCILLAZIONI VICINO AL MINIMO: CONSTANT DECAY)
- "LEARNING RATE SCHEDULES": AGGIUSTA IL LEARNING RATE DURANTE LA FASE DI TRAINING TENENDO IN CONSIDERAZIONE UNO SCHEMA PRE-DEFINITO:
  - CONSTANT: DEFAULT OPTION. LEARNING RATE FISSO DURANTE TRAINING
  - TIME-BASED:

$$\alpha^t = \alpha^0 \cdot \frac{1}{1+Kt}$$

(t: ITERATION NUMBER; K: DECAY RATE; SI PUO' ANCHE SOSTITUIRE t CON $\in$ EPOCA)

  - STEP-DECAY: IL LEARNING RATE SI RIDUCE DI UN FATTORE COSTANTE OGNI K EPOCHE

$$\alpha^{new} = \alpha^0 \cdot \frac{1}{2^d} \quad \text{DOVE } d = \left\lfloor \frac{\text{EPOCH}}{K} \right\rfloor$$

EPOCHE = COMPLETO PASSAGGIO DEI DATI IN UNA FASE DI TRAINING

SOLITAMENTE SI SCEGLIE DI RIDURRE IL LEARNING RATE DELLA METÀ OGNI $K = 10$ EPOCHE

  - EXPONENTIAL DECAY (PARAMETRO)

$$\alpha^t = \alpha^0 \cdot e^{-Kt}$$

(t: NUMERO DI ITERAZIONI DI TRAINING)

  - ADAPTIVE LEARNING RATE METHODS

IL PROBLEMA PRINCIPALE UTILIZZANDO UNO SCHEDULER PER IL LEARNING RATE E' LA DEFINIZIONE DEGLI IPERPARAMETRI DELLO SCHEDULER. COINVOLTI NELLA FORMULAZIONE (INFATTI QUESTI DIPENDONO DAL PROBLEMA DA RISOLVERE, DAI DATI E DAL MODELLO.

ESISTONO ALGORITMI DETTI DI "ADAPTIVE GRADIENT DESCENT" CHE POSSONO AIUTARE A RISOLVERE QUESTO PROBLEMA

- ☑ ADAGRAD: GRANDI UPDATE PER PARAMETRI SPARSI E PICCOLI UPDATE PER PARAMETRI NON SPARSI (SPARSI = VALORI IN INPUT DELLA COMPONENTE PARI A 0 MOLTE VOLTE)
- ☑ ADAM: AGGIUSTA ADAGRAD (MEDIA ACCELERATA, USA MOMENTUM E LEARNING RATE DIFFERENTE PER OGNUNO DEI PESI)

- MORE SOPHISTICATED APPROACHES EXIST FOR A BETTER TRAINING OF MORE COMPLEX MODELS (E.G. DEEP LEARNING MODELS). ONE OF THEM IS LARS (LAYER-WISE ADAPTIVE RATE SCALING) WHICH USE SEPARATE LEARNING RATE FOR EACH LAYER

OSSERVAZIONI

- $b \in$ # CAMPIONI NEL MINI BATCH (BATCH SIZE)
- $\alpha \in$ LEARNING RATE
- $e \in$ # EPOCHE (ITERAZIONI SGD) (AD OGNI EPOCA SI AGGIORNANO I PESI)
- $m \in$ # CAMPIONI

$\frac{m}{b} \in$ NUMERO DI BATCH DA CONSIDERARE PER OGNI EPOCA (AGGIORNO I VALORI I PESI) $\Rightarrow$ $\frac{m}{b}$ ITERAZIONI PER EPOCA $\Downarrow$ $e \cdot \frac{m}{b}$ ITERAZIONI

- MINIBATCH "GRANDI" PERMETTONO DI STIMARE MEGLIO IL GRADIENTE (PIU' E' GRANDE E PIU' SI AVVICINA AL GRADIENTE DI $J(\theta)$ SULL'INTERO SET DI DATI)
- PIU' GRANDE E' IL BATCH PIU' GRANDE E' LA STEP DA FARE NEL GRADIENTE (OVVERO α)

$b * K \rightarrow \alpha * K$ LINEAR SCALING

$b * K \rightarrow \alpha * \sqrt{K}$ ALTERNATIVE FOR FIX SCALING

$\frac{\alpha}{b}$ PIU' GRANDE E' QUESTO RAPPORTO E MIGLIORE LA CONDIZIONE PER RAGGIUNGERE MINIMO

CASO MULTI CLASSE

COME SI ESTENDE AL CASO MULTI CLASSE? K = NUMERO CLASSI

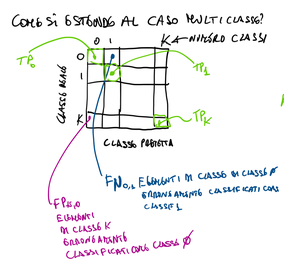

$$\text{ACCURACY} \quad \frac{\sum_k M_{kk}}{\sum_k \sum_j M_{kj}}$$

ROC CURVE

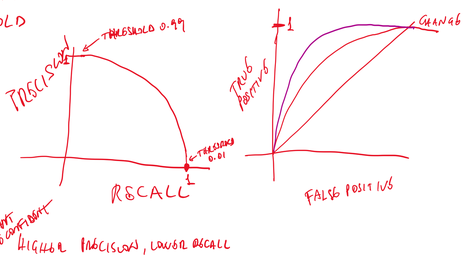

WE WANT TO BE CONFIDENT: HIGHER PRECISION, LOWER RECALL

WE WANT TO AVOID MANY CASES OF CANCER (AVOID FALSE NEGATIVE): HIGHER RECALL, LOWER PRECISION

NB: WE USE $h_\theta(x) \geq 0.5$ TO CLASSIFY (THRESHOLD) $\Rightarrow$ PRECISION AND RECALL WHEN WE USE THRESHOLD

SE CAMBIAMO LA THRESHOLD OTTENIAMO ALTRI VALORI DI PRECISION E RECALL

$\Rightarrow$ POSSIAMO GENERARE UN PLOT AL VARIARE DELLA THRESHOLD

IN RECALL THE DENOMINATOR DOES NOT DEPEND FROM THRESHOLD. LOWERING THRESHOLD INCREASE RECALL (INCREASE TP) LOWERING THE THRESHOLD MAY INCREASE THE DENOMINATOR OF PRECISION (INCREASE THE NUMBER OF POSITIVE A AND FALSE POSITIVE B) IF THRESHOLD IS TOO HIGH RESULT MAY BE ALL TRUE POSITIVE WHICH INCREASE PRECISION

F1 SCORE

$$F_1 = 2\frac{\text{PRECISION} \cdot \text{RECALL}}{\text{PRECISION} + \text{RECALL}}$$

FUNZIONA MEGLIO DI CONSIDERARE MEDIA DI PRECISION E RECALL

	PRECISION	RECALL	AVERAGE	F_1
MODEL 1	0.5	0.4	0.45	0.004
MODEL 2	0.7	0.1	0.4	0.175
MODEL 3	0.02	1	0.51	0.039

Predict always 1

$P = 0$ OPPURE $R = 0$ $\Downarrow$ $F_1 = 0$

$P = 1 \in R = 1$ $\Downarrow$ $F_1 = 1$